Moderne Datenanalyse mit R: Ein Einstieg für Aktuare

Modul I: Reproduzierbares Programmieren

Seminarreihe der ÖFdV
Dietmar Hareter, Fabian Pribahsnik

Reproduzierbare Analysen

Bekannte Situation:

Daten werden zum Beispiel mit RStudio aufbereitet und analysiert, wichtige Grafiken erstellt und die Ergebnisse anschließend manuell in Excel, Word oder PowerPoint übertragen.

Soll die Analyse einige Wochen später reproduziert oder mit geänderten Parametern neu erstellt werden, ist oft nicht mehr eindeutig nachvollziehbar, welcher Code und welche Daten zu den Ergebnissen geführt haben.

Herausforderungen:

- Analyse und Dokumentation sind voneinander getrennt.
- Ergebnisse sind schwer reproduzierbar.
- Änderungen erfordern einen hohen manuellen Aufwand.

Reproduzierbare Analysen

Lösungsansatz: Integrierte Workflows

Werkzeuge wie Jupyter Notebooks oder R Markdown lösen dieses Problem, indem sie Code, Ergebnisse und Dokumentation in einem einzigen, integrierten Dokument vereinen.

Was bedeutet Reproduzierbarkeit in diesem Zusammenhang?

Reproduzierbarkeit bedeutet, dass Analyseergebnisse ausschließlich auf Basis der bereitgestellten Daten und des verwendeten Codes vollständig nachvollziehbar und technisch wiederholbar sind.
Nur wenn die notwendigen Komponenten sauber dokumentiert sind, kann eine andere Person – oder man selbst zu einem späteren Zeitpunkt – exakt dieselben Ergebnisse erzeugen.

Jupyter Notebooks

Was ist Jupyter?

Jupyter ist eine Umgebung für interaktive Datenanalyse. Der Name leitet sich von den Programmiersprachen (Ju)lia, (Pyt)hon und R ab.

Was ist ein Jupyter Notebook?

Ein Jupyter Notebook ist ein Dokument, das verschiedene Arten von Inhalten kombiniert:

- Ausführbaren Code (Code-Zellen)
- Text und Dokumentation (Markdown-Zellen)
- Grafiken
- Tabellen
- Mathematische Formeln

Jupyter Notebooks

Der entscheidende Vorteil:

Der Code wird direkt im Dokument ausgeführt, und die Ergebnisse erscheinen unmittelbar darunter – transparent und nachvollziehbar.

Deshalb sind Jupyter Notebooks besonders geeignet für:

- Explorative Datenanalyse
- Prototypische Analysen
- Interaktive Demonstrationen

Dateiformat:

Ein Jupyter Notebook ist technisch gesehen eine reine Textdatei im JSON-Format mit Endung .ipynb (für Interactive Python Notebook).

Jupyter Notebooks

Funktionsweise:

Jupyter besteht aus zwei zentralen Komponenten:

1. Notebook-Interface: das eigentliche Dokument, bestehend aus
   - Code-Zellen
   - Markdown-Zellen (für Text und Dokumentation)
   - Grafiken und Visualisierungen
2. Kernel
   - Führt den Code aus
   - Speichert Variablen im Arbeitsspeicher
   - Liefert Ergebnisse zurück

Jupyter Notebooks

Einschränkung für R-User:

Jupyter ist ursprünglich ein Python-basiertes Tool! Das klassische Jupyter Notebook wird über eine Python-Umgebung installiert und gestartet.
R kann jedoch problemlos über einen separaten Kernel (IRkernel), der in R installiert werden muss, integriert werden. Erst dadurch steht R als auswählbare Sprache in Jupyter zur Verfügung.

Typische Vorgangsweise zur Installation:

- Python installieren (z.B. Anaconda oder Miniconda)
- Jupyter installieren
- In R auszuführen:
  - install.packages("IRkernel")
  - IRkernel::installspec()

Jupyter Notebooks | Shortcuts

Aktion	Shortcut
Zelle ausführen	Shift + Enter
Neue Zelle darunter	B
Neue Zelle darüber	A
Markdown-Zelle	M
Code-Zelle	Y
Kernel neu starten	Menü → Restart Kernel

R Markdown

Was ist R Markdown?

R Markdown ist ein Dateiformat (.Rmd) zur Erstellung von dynamischen Dokumenten, die Code, Text und Ergebnisse kombinieren.

Es ermöglicht die Erstellung von:

- Berichten
- Präsentationen
- Dashboards
- Dokumenten

R Markdown

Grundprinzip:

Ein R Markdown-Dokument besteht aus drei Elementen:

1. Text (Markdown)
   - Einfacher Text, Überschriften, Listen, Links, …
2. Code-Chunks
   - Blöcke mit ausführbarem R-Code
   - Speichert Variablen im Arbeitsspeicher
   - Liefert Ergebnisse zurück
3. Output
   - Tabellen
   - Berechnungen
   - Grafiken

R Markdown

Rendering:

Rendering ist der zentrale Unterschied zu Jupyter!

R Markdown funktioniert nicht wie Jupyter interaktiv, sondern

- der Code wird von oben nach unten ausgeführt
- die Ergebnisse werden in ein neues Dokument geschrieben

R Markdown | Chunk-Options

Option	Wirkung
echo=FALSE	Code nicht anzeigen
eval=FALSE	Code nicht ausführen
include=FALSE	Gar nichts anzeigen
message=FALSE	Paketmeldungen unterdrücken
warning=FALSE	Warnungen unterdrücken
fig.cap="Titel"	Bildunterschrift
cache=TRUE	Ergebnisse speichern

Vergleich R Markdown und Jupyter Notebook

Aspekt	R Markdown	Jupyter Notebook
Hauptfokus	Report-Erstellung	Exploration
Reproduzierbarkeit	Sehr hoch	Abhängig
Interaktivität	Gering bis mittel	Hoch
Output	HTML, PDF, Word	Notebook, HTML, PDF
Struktur	Linear	Zellbasiert
Typischer Einsatz	(Automatisierte) Berichte	Analysen

Quarto

Was ist Quarto (.qmd)?

Quarto ist der moderne Nachfolger von R Markdown und bietet mehrere Vorteile:

- Multi-Language-Support (R, Python, Julia, …) – ideal für moderne und größere Data-Science-Teams.
- Klarere Syntax und geringere Komplexität.
- Integration mit Jupyter: direkte Arbeit mit .ipynb-Dateien möglich. Damit bildet es eine Brücke zwischen der R- und der Python-Welt.

Warum sprechen wir dennoch über R Markdown?

- Viele bestehende Projekte und Reports basieren auf R Markdown.
- Stabilität und Reife (große Community, zahlreiche Beispiele und Tutorials).
- Für reine R-Projekte in der Praxis meist völlig ausreichend.